

先端データ解析論  
第三回 レポート

37-196360 森田涼介

2019 年 4 月 26 日

## 宿題 1

$$T(z) = \lambda|z| + u(\theta - z) + \frac{1}{2}(\theta - z)^2 \quad (\lambda \geq 0) \quad (1)$$

について,

$$\arg \min_z T(z) = \max(0, \theta + u - \lambda) + \min(0, \theta + u + \lambda) \quad (2)$$

であることを証明する。

$$\frac{\partial T}{\partial z} = \lambda \text{sign}(z) - u + (z - \theta) \quad (3)$$

$$= z - (\theta + u - \lambda \text{sign}(z)) \quad (4)$$

$$\frac{\partial^2 T}{\partial z^2} = 1 \quad (> 0) \quad (5)$$

より,  $T$  は下に凸な関数である。以下では  $z$  の正負について場合分けをし,  $T$  に最小を与える  $z$  を求める。

$z \geq 0$  のとき,

$$\frac{\partial T}{\partial z} = z - (\theta + u - \lambda) \quad (6)$$

1.  $\theta + u \leq \lambda$  のとき

$\forall z \geq 0$  に対して  $\partial T / \partial z \geq 0$  が成立し,  $T$  は増加関数となるので,  $T$  に最小を与える  $z = 0$  となる。

2.  $\theta + u \geq \lambda$  のとき

$T$  は下に凸な関数であるから,  $\partial T / \partial z = 0$  を与える  $z$  が  $T$  に最小を与える。よって  $z = \theta + u - \lambda$  となる。

これをまとめると,

$$\arg \min_z T(z) = \max(0, \theta + u - \lambda) \quad (7)$$

$z \leq 0$  のとき,

$$\frac{\partial T}{\partial z} = z - (\theta + u + \lambda) \quad (8)$$

1.  $\theta + u \geq -\lambda$  のとき

$\forall z \leq 0$  に対して  $\partial T / \partial z \leq 0$  が成立し,  $T$  は減少関数となるので,  $T$  に最小を与える  $z = 0$  となる。

2.  $\theta + u \leq -\lambda$  のとき

$\partial T / \partial z = 0$  を与える  $z = \theta + u + \lambda$  が  $T$  に最小を与える。

これをまとめると,

$$\arg \min_z T(z) = \min(0, \theta + u + \lambda) \quad (9)$$

以上をグラフで表すと, 図 1 のようになる。




図 1:  $z - \theta + u$  曲線

以上より,

$$\arg \min_z T(z) = \max(0, \theta + u - \lambda) + \min(0, \theta + u + \lambda) \quad (10)$$

であることがわかる。

## 宿題 2

ガウスカーネルモデルに対して、スパース回帰の交互方向乗数法による反復式を求め、また適当なモデルに対してスパース回帰を実行する。

ガウスカーネルモデルは次のように表される。

$$f_{\boldsymbol{\theta}}(\mathbf{x}) = \sum_{j=1}^n \theta_j K(\mathbf{x}, \mathbf{x}_j) \quad (11)$$

$$K(\mathbf{x}, \mathbf{c}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2h^2}\right) \quad (12)$$

このとき、L1 正則化を用いた最小二乗誤差は、

$$J(\boldsymbol{\theta}) = \frac{1}{2} \|\mathbf{K}\boldsymbol{\theta} - \mathbf{y}\|^2 + \lambda \|\boldsymbol{\theta}\|_1 \quad (13)$$

$$\mathbf{K} = \begin{bmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & \cdots & K(\mathbf{x}_1, \mathbf{x}_n) \\ \vdots & \ddots & \vdots \\ K(\mathbf{x}_n, \mathbf{x}_1) & \cdots & K(\mathbf{x}_n, \mathbf{x}_n) \end{bmatrix} \quad (14)$$

と表される。このとき、最適なパラメータ  $\hat{\boldsymbol{\theta}}$  は次のように求まる。

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} (J) \quad (15)$$

$J$  に最小を与える  $\boldsymbol{\theta}$  を、以下の設定で交互方向乗数法を用いることで求める。すなわち、

$$\boldsymbol{\theta} - \mathbf{z} = \mathbf{0} \quad (16)$$

$$l(\boldsymbol{\theta}) = \frac{1}{2} \|\mathbf{K}\boldsymbol{\theta} - \mathbf{y}\|^2 \quad (17)$$

$$g(\mathbf{z}) = \lambda \|\mathbf{z}\|_1 \quad (18)$$

の下で、

$$\min_{\boldsymbol{\theta}, \mathbf{z}} [l(\boldsymbol{\theta}) + g(\mathbf{z})] \quad (19)$$

を与える  $\boldsymbol{\theta}, \mathbf{z}$  を求める。このとき、拡張ラグランジュ関数は、

$$L(\boldsymbol{\theta}, \mathbf{z}, \mathbf{u}) = l(\boldsymbol{\theta}) + g(\mathbf{z}) + \mathbf{u}^T (\boldsymbol{\theta} - \mathbf{z}) + \frac{1}{2} \|\boldsymbol{\theta} - \mathbf{z}\|^2 \quad (20)$$

$$= \frac{1}{2} \|\mathbf{K}\boldsymbol{\theta} - \mathbf{y}\|^2 + \lambda \|\mathbf{z}\|_1 + \mathbf{u}^T (\boldsymbol{\theta} - \mathbf{z}) + \frac{1}{2} \|\boldsymbol{\theta} - \mathbf{z}\|^2 \quad (21)$$

であるから、 $\mathbf{K}$  は対称行列であることに注意すると、

$$\frac{\partial L}{\partial \boldsymbol{\theta}} = \mathbf{K}^2 \boldsymbol{\theta} - \mathbf{K} \mathbf{y} + \mathbf{u} + (\boldsymbol{\theta} - \mathbf{z}) \quad (22)$$

$$= (\mathbf{K}^2 + \mathbf{I}) \boldsymbol{\theta} - \mathbf{z} + \mathbf{u} - \mathbf{K} \mathbf{y} \quad (23)$$

$$\frac{\partial L}{\partial \mathbf{z}} = \lambda \frac{\partial \|\mathbf{z}\|_1}{\partial \mathbf{z}} - \mathbf{u} + (\mathbf{z} - \boldsymbol{\theta}) \quad (24)$$

$$= \mathbf{z} - (\boldsymbol{\theta} + \mathbf{u} - \lambda \text{sign}(\mathbf{z})) \quad (25)$$

となる。よって、更新式は、

$$\boldsymbol{\theta}^{(t+1)} = \arg \min_{\boldsymbol{\theta}} L(\boldsymbol{\theta}, \mathbf{z}^{(t)}, \mathbf{u}^{(t)}) \quad (26)$$

$$= (\mathbf{K}^2 + \mathbf{I})^{-1} (\mathbf{K}\mathbf{y} + \mathbf{z}^{(t)} - \mathbf{u}^{(t)}) \quad (27)$$

$$\mathbf{z}^{(t+1)} = \max(\mathbf{0}, \boldsymbol{\theta}^{(t+1)} + \mathbf{u}^{(t)} - \lambda) + \min(\mathbf{0}, \boldsymbol{\theta}^{(t+1)} + \mathbf{u}^{(t)} + \lambda) \quad (28)$$

$$\mathbf{u}^{(t+1)} = \mathbf{u}^{(t)} + \boldsymbol{\theta}^{(t+1)} - \mathbf{z}^{(t+1)} \quad (29)$$

となる。

いま、真のデータが

$$f(x) = \sin(\pi x) / (\pi x) + 0.1x \quad (-3 \leq x < 3) \quad (30)$$

から生成されていて、そのサンプルが 50 個ある場合を考える。このデータに対し L1 正則化付きガウスカーネルモデルを適用し、交差確認法によってそのハイパーパラメータ  $h, \lambda$  を推定する。いま、交差確認法のために、データを 5 分割し、それぞれのテスト誤差の平均をそのモデルのテスト誤差とした。また、テスト誤差には L1 正則化項は含まず、 $y$  の推定値と真の値の二乗和誤差のみを用いた。

$h, \lambda$  の値の候補は次の通りに設定した。

$$h = 1 \times 10^{-2}, 1 \times 10^{-1}, 1, 1 \times 10^1 \quad (31)$$

$$\lambda = 1 \times 10^{-6}, 1 \times 10^{-5}, 1 \times 10^{-4}, 1 \times 10^{-3}, 1 \times 10^{-2}, 1 \times 10^{-1} \quad (32)$$

また、ラグランジュ関数の値の変化（最大値と最小値の差）が直近 10 イタレーションで  $1 \times 10^{-3}$  より小さくなったときに更新を止めるように設定した。これは、前回の課題からテスト誤差は最適解付近で 1 のオーダーであることが分かっている、誤差 0.1% 以内ならば収束しているとみなせると考えられるからである。その結果、最適な  $h, \lambda$  及びこれらが与えるテスト誤差  $L$  は次のように求まった。

$$h = 1.0 \quad (33)$$

$$\lambda = 1 \times 10^{-4} \quad (34)$$

$$L = 1.31 \quad (35)$$

交差確認法の結果を図 2 に示す。また、プログラムは 6 ページの Listing 1 に記載した。

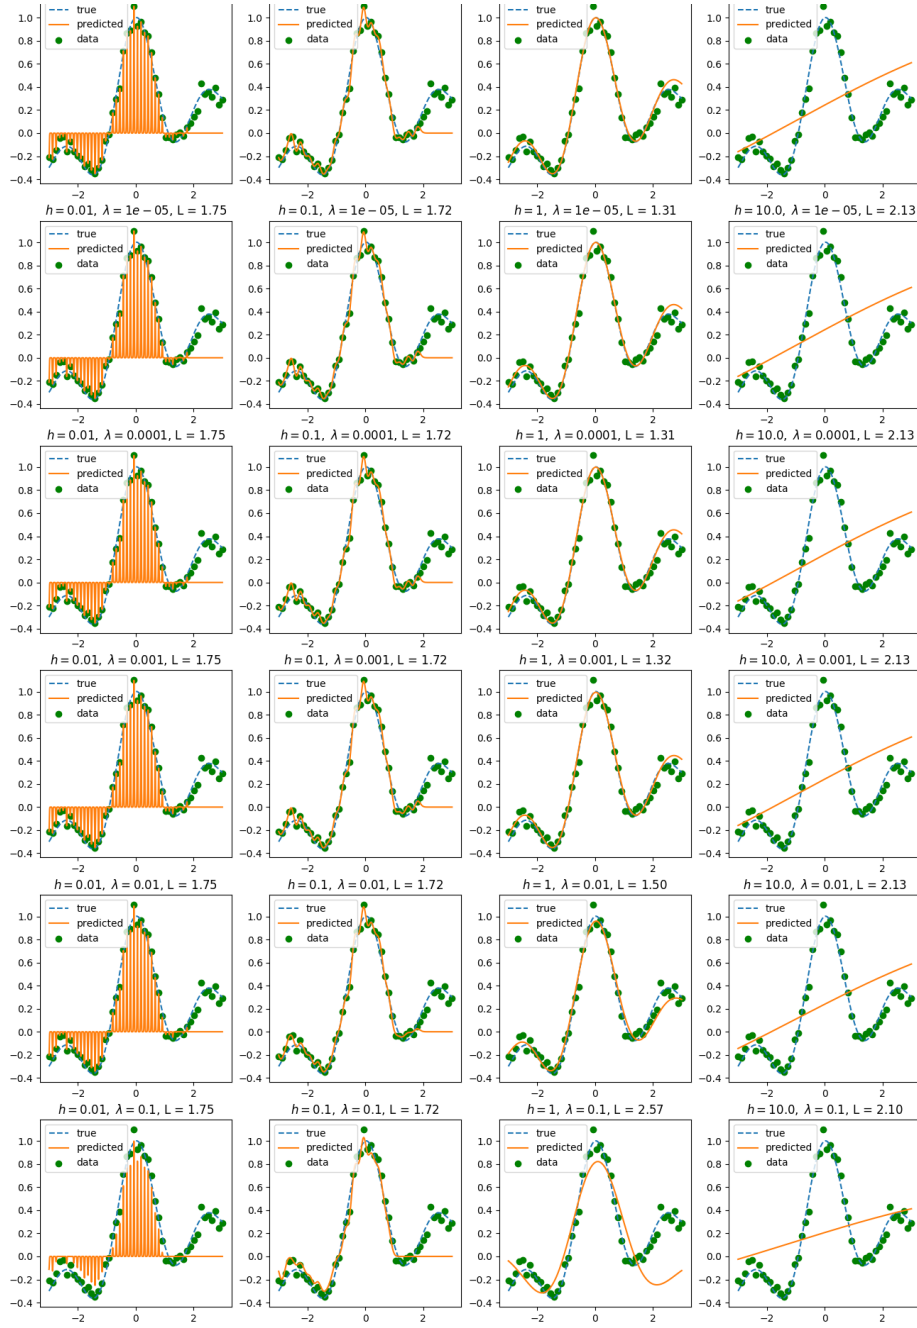


図 2: 交差確認法の結果

## プログラム

実行環境と用いた言語・ライブラリを以下の表 1 に示す。

表 1: プログラムの実行環境

OS	: Microsoft Windows 10 Pro (64bit)
CPU	: Intel(R) Core(TM) i5-4300U
RAM	: 4.00 GB
使用言語	: Python3.6
可視化	: matplotlib ライブラリ

### Listings 1: assignment2.py

```
1  # -*- coding: utf-8 -*-
2
3
4  import numpy as np
5  import matplotlib.pyplot as plt
6
7
8  def true_model(x):
9      pix = np.pi * x
10     target = np.sin(pix) / pix + 0.1 * x
11     return target
12
13
14  def gauss_kernel(x, c, h):
15     return np.exp(-(x - c)**2 / (2*h**2))
16
17
18  def generate_sample(xmin, xmax, sample_size):
19     x = np.linspace(start=xmin, stop=xmax, num=sample_size)
20     target = true_model(x)
21     noise = 0.05 * np.random.normal(loc=0., scale=1., size=sample_size)
22     return x, target + noise
23
24
25  def split(x, y, n_split=5):
26     n_data = len(y)
27     n_data_in_one_split = int(n_data / n_split)
28     idx = np.arange(n_data)
29     np.random.shuffle(idx)
30
31     x_split = []
32     y_split = []
```

```

33     for i in range(n_split):
34         idx_start = i * n_data_in_one_split
35         idx_end = (i+1) * n_data_in_one_split
36         if idx_end == n_data:
37             idx_end = None
38         x_split.append(x[idx_start:idx_end])
39         y_split.append(y[idx_start:idx_end])
40     return x_split, y_split
41
42
43 def split_train_test(x_split, y_split, k):
44     n_split = len(y_split)
45     x_test, y_test = x_split[k], y_split[k]
46     x_train, y_train = [], []
47     for _k in range(n_split):
48         if _k != k:
49             x_train.extend(x_split[_k])
50             y_train.extend(y_split[_k])
51     x_train = np.array(x_train)
52     y_train = np.array(y_train)
53     return x_train, y_train, x_test, y_test
54
55
56 def calc_design_matrix(x, c, h, kernel):
57     return kernel(x[None], c[:, None], h)
58
59
60 def solve_gauss_kernel_model(x, y, h, lamb):
61     k = calc_design_matrix(x, x, h, gauss_kernel)
62     theta = np.linalg.solve(
63         k.T.dot(k) + lamb*np.identity(len(k)),
64         k.T.dot(y[:, None]),
65     )
66     return theta
67
68
69 def solve_gauss_kernel_sparse_model(x, y, h, lamb, eps=1e-2, iter_max=100,
70     n_look=5):
71     def update(theta, z, u, lamb, K, y):
72         theta = np.linalg.inv(K.T.dot(K) + np.eye(len(K))).dot(K.dot(y[:,
73             None]) + z - u)
74
75         z_plus = theta + u - lamb
76         z_plus[z_plus < 0] = 0
77         z_minus = theta + u + lamb
78         z_minus[z_minus > 0] = 0
79         z = z_plus + z_minus

```



```

78
79     u = u + theta - z
80     return theta, z, u
81
82 def compute_lagrange_func(theta, z, u, lamb, K, y):
83     loss = (
84         (1/2) * np.linalg.norm(K.dot(theta) - y)
85         + lamb * np.linalg.norm(z, ord=1)
86         + u.T.dot(theta - z)
87         + (1/2) * np.linalg.norm(theta - z)
88     )
89     return loss
90
91 K = calc_design_matrix(x, x, h, gauss_kernel)
92 theta = np.linalg.solve(K.T.dot(K), K.T.dot(y[:, None]))
93 z = np.random.rand(*theta.shape) * 0.1
94 u = np.random.rand(*theta.shape) * 0.1
95 lagrange_list = []
96 for i in range(iter_max):
97     theta, z, u = update(theta, z, u, lamb, K, y)
98     lagrange = compute_lagrange_func(theta, z, u, lamb, K, y)
99     if i < n_look:
100         lagrange_list.append(lagrange)
101     else:
102         lagrange_list = lagrange_list[1:] + [lagrange]
103         if max(lagrange_list) - min(lagrange_list) < eps:
104             break
105 return theta, z, u, i+1
106
107
108 def compute_loss(x_train, x_test, y, h, theta, lamb):
109     k = calc_design_matrix(x_train, x_test, h, gauss_kernel)
110     loss = (1/2)*np.linalg.norm(k.dot(theta) - y)
111     # loss += (lamb/2)*np.linalg.norm(theta)
112     return loss
113
114
115 def main():
116     np.random.seed(0) # set the random seed for reproducibility
117
118     # create sample
119     xmin, xmax = -3, 3
120     sample_size = 50
121     n_split = 5
122     x, y = generate_sample(xmin=xmin, xmax=xmax, sample_size=sample_size)
123     # print(x.shape, y.shape)
124

```

```

125     x_split, y_split = split(x, y, n_split=n_split)
126     # print(x_split[0].shape, y_split[0].shape)
127
128     # global search
129     h_cands = [1e-2, 1e-1, 1, 1e1,]
130     lamb_cands = [1e-6, 1e-5, 1e-4, 1e-3, 1e-2, 1e-1,]
131
132     # local search
133     #searched_range_base = np.arange(0.5, 1.5, 0.1)
134     #h_cands = 1.0 * searched_range_base
135     #lamb_cands = 1e-6 * searched_range_base
136
137     loss_min = 1e8
138     h_best = None
139     lamb_best = None
140     theta_best = None
141     n_iter_best = None
142
143     n_row = len(lamb_cands)
144     n_col = len(h_cands)
145     fig = plt.figure(figsize=(n_col*4, n_row*4))
146     fig_idx = 0
147
148     for lamb in lamb_cands:
149         for h in h_cands:
150             losses = []
151             for k in range(n_split):
152                 x_train, y_train, x_test, y_test = split_train_test(x_split,
153                 y_split, k)
154                 # print(x_train.shape, y_train.shape)
155
156                 theta, z, u, n_iter = solve_gauss_kernel_sparse_model(
157                     x_train, y_train, h, lamb,
158                     eps=1e-3, iter_max=200, n_look=10,
159                     )
160                 loss_k = compute_loss(x_train, x_test, y_test, h, theta,
161                 lamb)
162                 losses.append(loss_k)
163             loss = np.mean(losses)
164
165             if loss < loss_min:
166                 loss_min = loss
167                 h_best = h
168                 lamb_best = lamb
169                 theta_best = theta
170                 n_iter_best = n_iter

```

```

170         # for visualization
171         X = np.linspace(start=xmin, stop=xmax, num=5000)
172         true = true_model(X)
173         K = calc_design_matrix(x_train, X, h, gauss_kernel)
174         prediction = K.dot(theta)
175
176         # visualization
177         fig_idx += 1
178         ax = fig.add_subplot(n_row, n_col, fig_idx)
179         ax.set_title('$h = {}, \backslash \lambda = {}$, L = {:.2f}'.format(h,
lamb, loss))
180         ax.scatter(x, y, c='green', marker='o', label='data')
181         ax.plot(X, true, linestyle='dashed', label='true')
182         ax.plot(X, prediction, linestyle='solid', label='predicted')
183         ax.legend()
184
185     print('Best Model')
186     print('\th = {}'.format(h_best))
187     print('\tlambda = {}'.format(lamb_best))
188     print('\tloss = {}'.format(loss_min))
189     print('\tn_iter: {}'.format(n_iter_best))
190     print('\ttheta: \n', theta_best)
191
192     plt.savefig('../figures/assignment2_result.png')
193     plt.show()
194
195
196 if __name__ == '__main__':
197     main()

```